Selección de Ubicaciones Comerciales en Melbourne mediante Aprendizaje No Supervisado; Caso Cafetería Saludable

1. Definición del Problema

A la hora de abrir un negocio de hostelería o una tienda física en el centro de una ciudad, el error más común es fijarse únicamente en el volumen total de gente que pasa por una calle al cabo del año. Que una avenida tenga millones de peatones anuales no garantiza que un local vaya a funcionar: por ejemplo, una calle por la que pasan miles de oficinistas corriendo a las ocho de la mañana puede ser buena para vender café para llevar, pero fracasa si quieres montar un restaurante de cenas o de fin de semana. Del mismo modo, meterte en la calle más transitada de la ciudad suele significar entrar en una zona donde ya hay cien competidores directos.

Al revisar los datos abiertos del Ayuntamiento de Melbourne de 2019 (último año completo antes de los cierres por la pandemia), encontré un dato muy llamativo en su censo comercial (CLUE): de los 19.730 locales registrados en el centro de la ciudad, la categoría más frecuente es precisamente la de locales vacíos (Vacant Space), con 3.011 inmuebles registrados como vacíos, justo por delante de las cafeterías y restaurantes (1.802) y de los locales de comida para llevar (721). Al mismo tiempo, la ciudad cuenta con una red de sensores que registró 456.829 conteos horarios de peatones durante ese año.

Como no existe una columna o etiqueta previa en los datos que nos diga qué esquinas son “buenas” o “malas” para invertir, estamos ante un problema real de aprendizaje no supervisado. La idea de este trabajo es cruzar el tráfico horario de los sensores con los negocios que rodean a cada sensor para agrupar las calles según su comportamiento real y recomendar en qué locales vacíos concretos merece la pena abrir un café saludable.

Conviene aclarar desde el principio que “saludable” es un posicionamiento de negocio y no una variable que el modelo pueda medir: lo que el modelo identifica son zonas favorables para una cafetería (mucha demanda peatonal por competidor y locales vacíos cerca), y el carácter saludable del concepto es el criterio de negocio con el que se interpretan esas recomendaciones.

2. Objetivos del Trabajo

El objetivo principal es diseñar un modelo práctico basado en algoritmos de clustering y reducción de dimensionalidad que agrupe las zonas de Melbourne según su flujo peatonal y su entorno comercial, para terminar recomendando las mejores direcciones de locales vacíos donde abrir un café saludable.

Este objetivo general se divide en cinco pasos concretos:

- **1. Limpiar y cruzar las fuentes de datos:** Filtrar los sensores que funcionaron de forma fiable durante 2019 (al menos el 90% de las horas del año) y resumir tanto sus franjas horarias de paso como el número de negocios que tienen en un radio de 200 metros.
- **2. Comprobar la tendencia de agrupamiento y reducir dimensiones:** Verificar matemáticamente que los datos no se distribuyen al azar (usando el estadístico de Hopkins) y proyectar la tabla de variables a 2 dimensiones con PCA para poder visualizar los sensores.
- **3. Comparar tres algoritmos de clustering de distinta naturaleza:** Aplicar K-Means++ (basado en centroides), Clustering Jerárquico Aglomerativo con enlace Ward (basado en jerarquía) y DBSCAN (basado en densidad) para identificar tanto los perfiles principales de calles como los puntos atípicos.
- **4. Evaluar la calidad y estabilidad de los modelos:** Medir cómo de compactos y separados quedan los grupos con criterios internos (Silueta y Davies-Bouldin) y comprobar qué algoritmo aguanta mejor al añadir ruido gaussiano con criterios externos (Rand Ajustado y V-Medida).
- **5. Tomar una decisión de negocio justificable:** Definir un indicador de oportunidad que cruce la demanda peatonal por competidor con la disponibilidad de locales vacíos, extraer las direcciones exactas a pie de calle, comprobar mediante un análisis de sensibilidad que el resultado no depende de los pesos elegidos y validar espacialmente el Top 3 sobre un mapa.

3. Glosario Breve de Términos

Para que el informe y el cuaderno de código se sigan sin dificultad, resumo aquí de forma sencilla los conceptos técnicos y del dominio que aparecen a lo largo del estudio:

Término	Explicación sencilla aplicada al trabajo
Censo CLUE y Vacant Space	Censo anual de uso del suelo y empleo de Melbourne. La categoría 'Vacant Space' indica locales comerciales registrados como vacíos en 2019; el censo no indica si estaban en alquiler ni a qué precio.
Cobertura del sensor	Porcentaje de horas del año 2019 (sobre un total de 8.760 horas) en las que un sensor estuvo operativo y registró datos sin cortes por obras o averías.
StandardScaler (Z-score)	Técnica de escalado que resta la media y divide por la desviación típica para que todas las variables tengan media 0 y desviación 1, evitando que las variables con números grandes manden sobre las demás.
Estadístico de Hopkins (H)	Prueba que compara las distancias entre nuestros datos con las de puntos generados al azar. Si H se acerca a 1 (o 1-H se acerca a 0), confirma que los datos tienden a formar grupos reales.
PCA (Componentes Principales)	Técnica que resume nuestras 11 variables originales en nuevas variables (PC1, PC2) que concentran la mayor parte de la información (varianza) para poder graficar en 2D.
Inercia (WCSS) y Método del Codo	Suma de las distancias al cuadrado de cada punto al centro de su grupo en K-Means. Al graficarla para varios valores de K, buscamos el punto donde la curva hace un 'codo' y deja de bajar brusco.
Ruido (-1) en DBSCAN	Puntos que no tienen suficientes vecinos cerca dentro del radio marcado (eps). En este proyecto no son datos erróneos, sino calles con cifras récord de peatones o de locales vacíos.
Criterios Internos (Silueta / DB)	Métricas que evalúan la calidad del clustering sin usar etiquetas externas.

	Silueta (entre -1 y 1) es mejor cuanto más alta; Davies-Bouldin es mejor cuanto más cerca de 0.
Criterios Externos (ARI / V-Medida)	Métricas que comparan dos particiones entre sí. Aquí las usamos para comparar los grupos originales con los que salen tras meter ruido aleatorio a los datos y ver si el modelo es estable.
Zona de influencia (200 m)	Círculo de 200 metros alrededor de cada sensor dentro del cual se cuentan los negocios. Si dos sensores están cerca, sus círculos se solapan y comparten establecimientos.

4. Herramientas y Conjuntos de Datos Utilizados

Todo el desarrollo se ha hecho en Python dentro de un cuaderno de Jupyter (trabajoFinal_AA_Erik_Enriquez.ipynb), utilizando principalmente las librerías vistas en clase:

- • **Manipulación y cálculo:** pandas y numpy para limpiar tablas, cruzar coordenadas y hacer la simulación de sensibilidad.
- • **Visualización:** matplotlib y seaborn para las curvas horarias, mapas de calor de centroides y gráficos de dispersión, además de folium únicamente para el mapa final de validación espacial del Top 3.
- • **Aprendizaje automático:** scikit-learn (StandardScaler, NearestNeighbors, PCA, KMeans, AgglomerativeClustering, DBSCAN y métricas de evaluación del módulo sklearn.metrics).

En cuanto a los datos, partimos de cuatro ficheros CSV obtenidos del portal de datos abiertos de Melbourne para el año 2019:

Fichero CSV	Tamaño original	Qué información contiene y cómo se usa
peatones_2019.csv	456.829 filas x 10 cols	Conteos horarios de peatones (Hourly_Counts) por sensor, fecha, día de la semana y hora (0 a 23h).
sensores_2019.csv	48 filas x 12 cols	Catálogo de sensores con su identificador (location_id), nombre de la calle y coordenadas GPS (latitud y longitud).
cobertura_sensores_2019.csv	58 filas x 3 cols	Horas con dato registradas por cada sensor en 2019 y su proporción sobre las 8.760 horas del año.
establecimientos_2019.csv	19.730 filas x 12 cols	Locales del censo CLUE 2019 con su dirección postal exacta, rubro de actividad (ANZSIC4) y coordenadas GPS.

5. Metodología de Trabajo

Para mantener un orden claro y que cada paso sirva de base al siguiente, organicé el cuaderno en cinco fases:

- **Fase 1 (Preprocesado e Ingeniería de Variables):** Limpieza de nulos, filtrado de sensores con cobertura mayor o igual al 90%, codificación del tipo de día, resumen del flujo en 4 franjas horarias, conteo de locales a menos de 200 metros y estandarización con StandardScaler.

- **Fase 2 (Tendencia de Clustering y Reducción de Dimensión):** Cálculo del estadístico de Hopkins para validar que existen grupos y reducción de las 11 variables a 2 componentes principales con PCA.
- **Fase 3 (Modelado No Supervisado):** Entrenamiento de K-Means++ (seleccionando K=3 con el método del codo), Clustering Jerárquico Aglomerativo con enlace Ward y DBSCAN para detectar zonas densas y anomalías.
- **Fase 4 (Selección y Evaluación de Modelos):** Comparación de los tres algoritmos mediante criterios internos (Silueta y Davies-Bouldin) y prueba de resistencia al ruido con criterios externos (ARI y V-Medida).
- **Fase 5 (Decisión de Negocio, Sensibilidad y Validación Espacial):** Cálculo del Score de Oportunidad Comercial para elegir los 3 mejores sensores, búsqueda de las direcciones exactas de locales vacíos cercanos, validación mediante 5.000 combinaciones aleatorias de pesos, análisis del mejor sensor de cada arquetipo y comprobación del Top 3 sobre un mapa.

6. Desarrollo y Resultados del Análisis

6.1. Fase 1: Limpieza, Ingeniería de Variables y Escalado

Al revisar los valores nulos en las columnas clave de establecimientos_2019.csv, vi que solo había 2 locales sin coordenadas GPS de un total de 19.730, así que eliminé esas dos filas con dropna(). Después crucé la tabla de sensores con la de cobertura anual: de los 48 sensores que tenían coordenadas registradas, me quedé únicamente con los 41 sensores que funcionaron al menos el 90% de las horas del año. Hacer este filtro es importante porque si incluyes un sensor que estuvo apagado seis meses por obras en la acera, su media horaria sale artificialmente baja y engaña al modelo.

A continuación, transformé la columna categórica del día de la semana (Day) en dos categorías: Laborable (lunes a viernes) y Fin_de_semana (sábado y domingo), aplicando get_dummies(). Al graficar el pulso horario medio de la ciudad para ambos tipos de día se ve claramente por qué no basta con mirar la media anual:

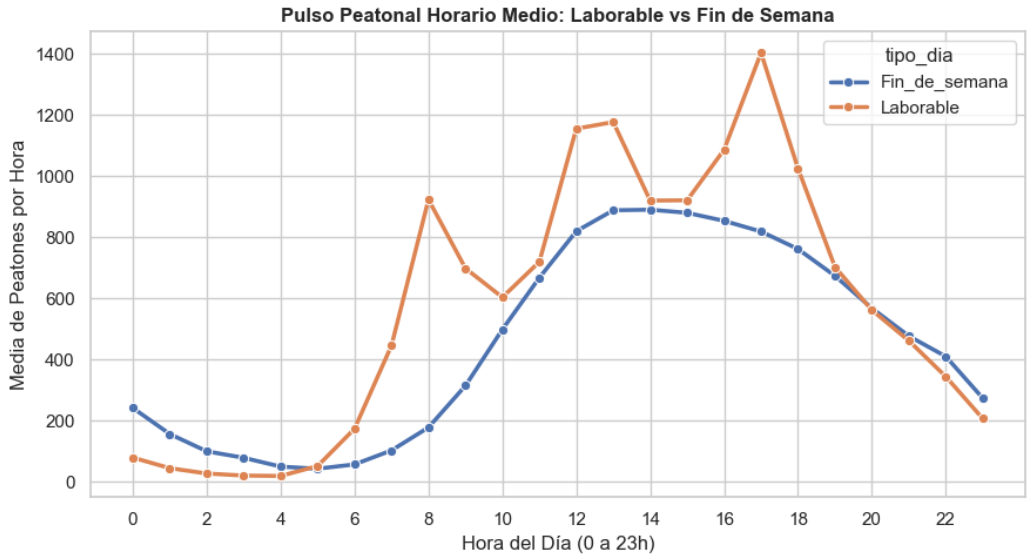


Figura 1. Pulso peatonal horario medio en Melbourne (2019) separando días laborables y fines de semana.

En la Figura 1 se aprecia que los días laborables tienen tres picos muy marcados: la entrada a las oficinas a las 8:00h (más de 900 peatones/hora), la hora de comer entre las 12:00h y las 13:00h (casi 1.200 peatones/hora) y la salida del trabajo a las 17:00h (1.400 peatones/hora). En cambio, el fin de semana la curva sube despacio por la mañana, forma una meseta suave entre las 12:00h y las 17:00h (alrededor de 850-900 peatones/hora) y aguanta con más gente por la noche.

Con esto claro, construí una tabla maestra donde cada fila es uno de los 41 sensores y las 11 columnas numéricas resumen su tráfico y los negocios que tiene alrededor en un radio de 200 metros (calculando la distancia euclídea en metros desde las coordenadas de cada sensor):

- • **4 variables de franjas horarias:** flujo_manana (6 a 10h), flujo_mediodia (11 a 15h), flujo_tarde (16 a 20h) y flujo_noche (21 a 5h).
- • **3 variables de tipo de día:** flujo medio en Laborable, flujo medio en Fin_de_semana y la proporción ratio_finde = Fin_de_semana / (Laborable + 1).
- • **4 variables del entorno comercial a 200 m:** locales_vacios (Vacant Space), cafes_restaurantes, comida_llevar (Takeaway) y oficinas_servicios (suma de despachos legales, informática, finanzas y consultoría).

Como las variables de flujo peatonal alcanzan valores cercanos a 3.000 personas por hora mientras que el ratio_finde se mueve alrededor de 1, apliqué StandardScaler sobre las 11 variables. Así todas pasan a tener media 0 y desviación típica 1 y pesan lo mismo al calcular distancias.

6.2. Fase 2: Tendencia de Clustering (Hopkins) y Reducción de Dimensión (PCA)

Antes de lanzar K-Means, hay que comprobar si los datos realmente tienen tendencia a agruparse, porque K-Means te divide cualquier nube de puntos aunque sea totalmente aleatoria. Para verificarlo programé el estadístico de Hopkins promediando 50 simulaciones. El resultado fue H = 0,7490 en la formulación clásica (donde valores cercanos a 1 indican agrupamiento claro frente a 0,50 aleatorio) y 1 - H = 0,2510 en el criterio usado en Python (cercano a 0). Esto confirma que los sensores sí forman grupos naturales.

Después apliqué PCA (Análisis de Componentes Principales) sobre las 11 variables estandarizadas para reducir la dimensión y poder representar los sensores en un plano 2D:

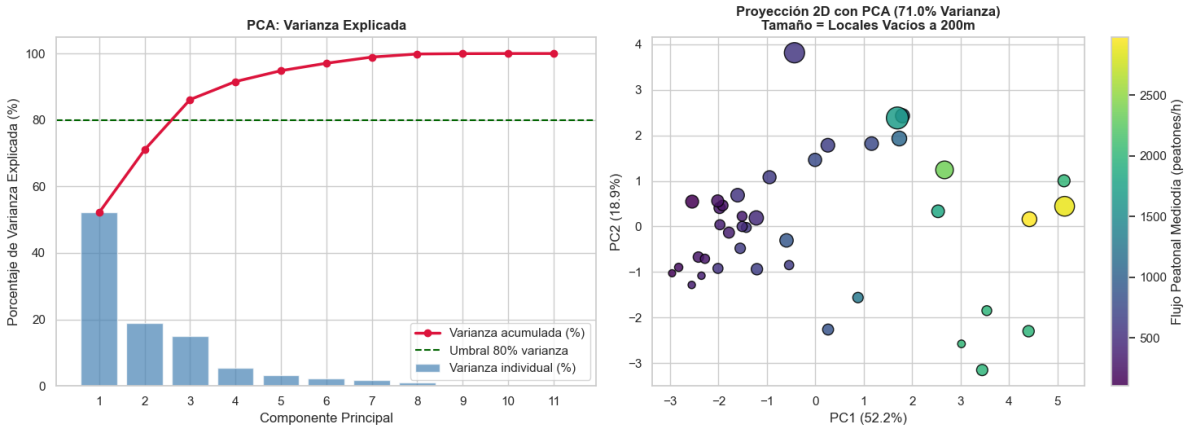


Figura 2. Varianza explicada por componente en PCA (izquierda) y proyección 2D de los 41 sensores (derecha).

Como muestra la Figura 2, la primera componente (PC1) recoge por sí sola el 52,2% de la varianza (representa el volumen general de gente y comercios), y la segunda componente (PC2) aporta otro 18,9% (separa las calles de oficinas matutinas de las zonas de ocio y restauración). Entre las dos primeras componentes retenemos el 71,0% de toda la información original (y con tres componentes superamos el 86%), lo que permite visualizar el mapa de sensores en 2D sin perder apenas detalle.

6.3. Fase 3: Modelado No Supervisado (K-Means++, Jerárquico y DBSCAN)

1. K-Means++ y Método del Codo: Calculé la inercia intra-clúster (WCSS) desde K=1 hasta K=10 usando inicialización k-means++ para evitar malas semillas iniciales. En la gráfica del codo (Figura 3, izquierda) se ve que a partir de K = 3 la caída de la inercia se suaviza y nos deja tres perfiles de calles muy fáciles de interpretar desde el punto de vista comercial:

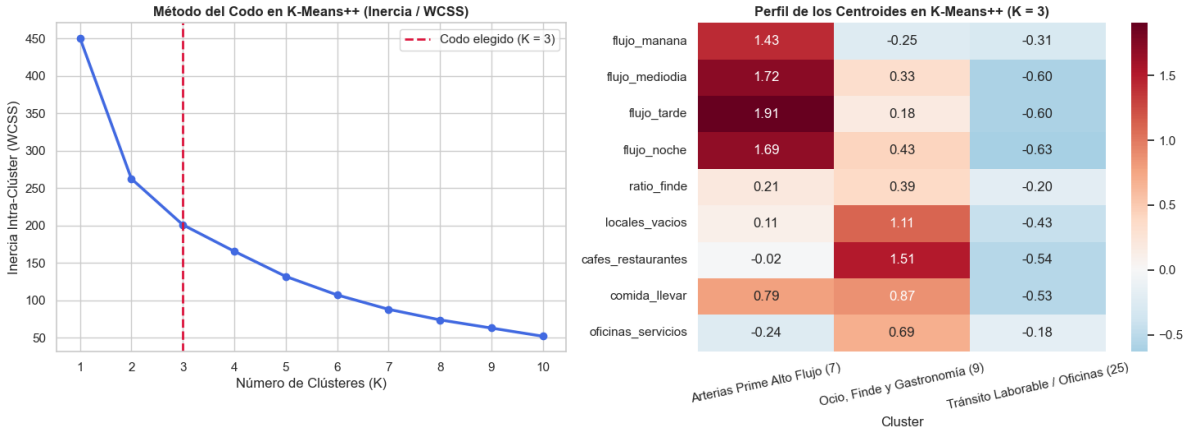


Figura 3. Método del codo en K-Means++ (izquierda) y mapa de calor de los centroides para K = 3 (derecha).

Arquetipo K-Means++ (Sensores)	Flujo Mañana / Mediodía / Tarde / Noche	Ratio Finde	Vacíos / Cafés / Takeaway / Oficinas (200m)	Lectura práctica de negocio
Clúster 0: Ocio, Finde y Gastronomía (9)	363,3 / 1.192,6 / 1.026,5 / 219,1	1,0	107,9 / 113,0 / 44,0 / 90,6	Calles con muchísima vida en fin de semana, récord de restaurantes (113) y gran bolsa de locales vacíos (107,9).
Clúster 1: Tránsito Laborable / Oficinas (25)	336,4 / 470,2 / 437,6 / 65,3	0,7	33,4 / 29,2 / 9,8 / 29,8	La mayoría de calles secundarias o de paso laboral: tráfico moderado entre semana que se apaga por la noche y los domingos.
Clúster 2: Arterias Prime Alto Flujo (7)	1.089,3 / 2.262,0 / 2.337,3 / 404,4	0,9	59,7 / 50,3 / 42,0 / 25,6	Los grandes ejes peatonales del centro: más de 2.200 personas por hora al mediodía y por la tarde todos los días.

2. Clustering Jerárquico Aglomerativo (enlace Ward, K = 3): Al aplicar el agrupamiento jerárquico con criterio de mínima varianza (Ward) cortando en 3 grupos, el algoritmo reparte los sensores en tamaños

de 27, 10 y 4 sensores, una división muy parecida a la de K-Means++ que confirma que en la ciudad hay un grupo mayoritario de calles normales, un grupo intermedio comercial y un grupo pequeño de arterias de altísimo flujo.

3. DBSCAN y detección de anomalías (-1): Para elegir el radio eps probé un barrido entre 1,8 y 2,8 manteniendo min_samples = 3. Vi que en eps = 2,4 (y 2,6) el resultado se estabiliza en 2 clústeres densos y 4 puntos de ruido (-1). Lo interesante de DBSCAN en este trabajo es ver qué son esos 4 puntos que deja fuera como ruido:

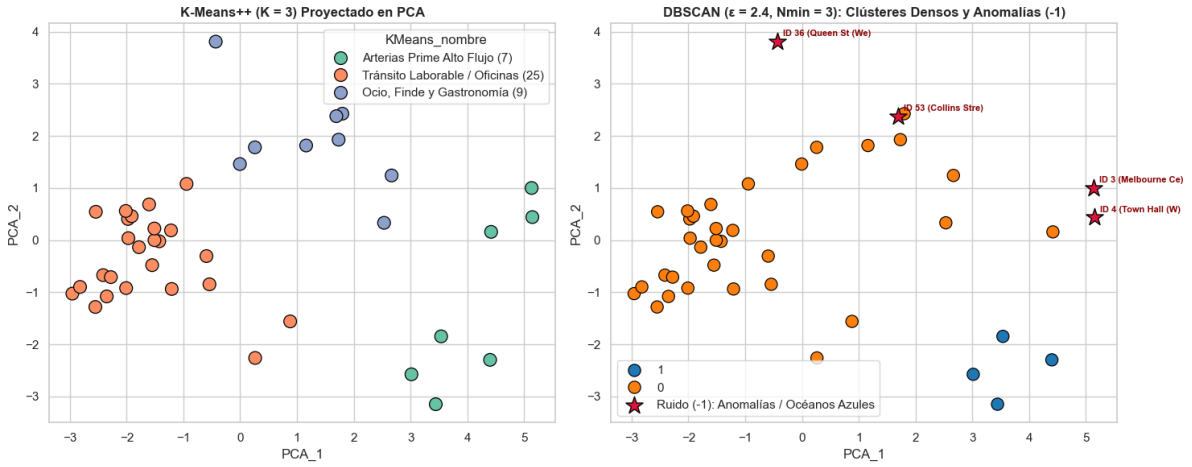


Figura 4. Comparación en el plano PCA entre los 3 grupos de K-Means++ (izquierda) y la salida de DBSCAN con las 4 anomalías marcadas con estrellas rojas (derecha).

Sensor ID y Calle	Grupo en K-Means++	Flujo Mediodía / Tarde	Locales Vacíos (200m)	Cafeterías / Oficinas	Por qué DBSCAN lo marca como anomalía (-1)
ID 4: Town Hall (West)	Arterias Prime (7)	2.882,4 / 2.465,3	175	66 / 68	Combina un flujo peatonal enorme (casi 2.900/h) con una bolsa muy alta de locales vacíos (175).
ID 53: Collins Street (North)	Ocio y Gastronomía (9)	1.683,1 / 944,1	224	86 / 119	Tiene el mayor número de locales vacíos de los 41 sensores (224 en 200 m) junto a 119 oficinas.
ID 3: Melbourne Central	Arterias Prime (7)	2.002,3 / 2.353,7	49	100 / 27	Nodo comercial y de transporte que supera las 2.350 personas/h por la tarde con 100 cafeterías alrededor.
ID 36: Queen St (West)	Ocio y Gastronomía (9)	573,5 / 407,1	187	66 / 412	Concentración extrema de despachos

					profesionales: 412 oficinas y 187 locales vacíos en 200 m.

Nota: los sensores 4 y 53 distan solo 99 m entre sí (véase el apartado 6.6), por lo que en la práctica son un mismo foco comercial observado desde dos sensores y sus cifras de locales vacíos no deben sumarse.

6.4. Fase 4: Selección y Evaluación de Modelos

Evalué los tres algoritmos desde dos ángulos distintos: primero con criterios internos (sin etiquetas) y luego con criterios externos inyectando ruido aleatorio (30 repeticiones sumando ruido gaussiano con desviación 0,25 sobre los datos escalados) para comprobar qué modelo mantiene mejor sus grupos cuando los datos sufren pequeñas variaciones.

Algoritmo Evaluado	Silhouette (↑ mejor)	Davies-Bouldin (↓ mejor)	Rand Ajustado ARI (↑ mejor)	V-Medida ante ruido (↑ mejor)
K-Means++ (K = 3)	0,386	1,150	0,897	0,864
Jerárquico Ward (K = 3)	0,396	1,001	0,760	0,738
DBSCAN (eps = 2,4, Nmin = 3)	0,423 (sin ruido)	0,758 (sin ruido)	0,641	0,621

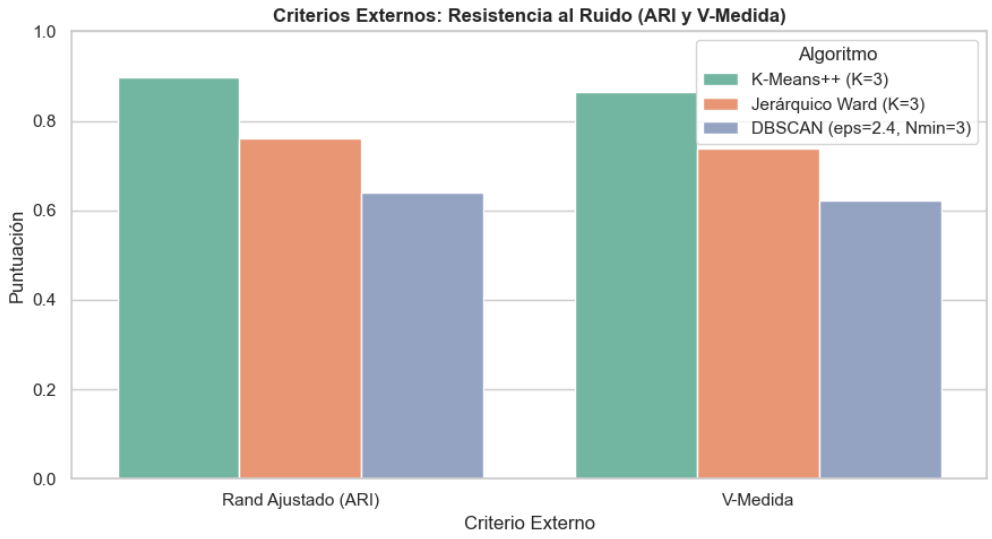


Figura 5. Estabilidad frente al ruido gaussiano medida con Rand Ajustado (ARI) y V-Medida en 30 simulaciones.

La tabla y la Figura 5 muestran un resultado muy interesante para comentar en la exposición: si miramos solo las métricas internas sin ruido, DBSCAN gana (Silueta de 0,423 y Davies-Bouldin de 0,758) porque se quita de encima los 4 puntos más extremos y deja grupos más compactos. En cambio, cuando metemos ruido a los datos, K-Means++ es con diferencia el más sólido y estable (ARI = 0,897 y V-Medida = 0,864), mientras que DBSCAN baja a 0,641 porque un pequeño cambio en los datos hace que los puntos cercanos al borde del radio eps pasen de estar dentro de un grupo a ser marcados como ruido. Por eso

en la Fase 5 combino la visión de ambos: uso los perfiles estables de K-Means++ y presto especial atención a las esquinas singulares detectadas por DBSCAN.

6.5. Fase 5: Decisión de Negocio, Direcciones Recomendadas y Sensibilidad

Para pasar del clustering a una recomendación concreta para un inversor interesado en abrir un café saludable, primero apliqué un filtro básico: exigir que alrededor del sensor haya al menos 15 locales vacíos (locales_vacios >= 15) para asegurar que hay varios locales vacíos entre los que elegir. Después definí dos ratios de demanda no saturada (sumando 5 al denominador para estabilizar el cociente si una calle tiene muy pocos locales):

- • **Demanda por cafetería:** (flujo_mediodia + flujo_tarde) / (cafes_restaurantes + 5).
- • **Demanda por takeaway:** (flujo_manana + flujo_mediodia + flujo_tarde) / (comida_llevar + 5).

Con estas variables construí un Score de Oportunidad Comercial (de 0 a 100) eligiendo los pesos a priori por criterio de negocio antes de mirar el ranking:

- • **0,5 para la demanda por cafetería:** Porque el negocio objetivo es un café saludable y esta ratio mide directamente cuántos clientes potenciales pasan por cada competidor directo (las cafeterías).
- • **0,3 para la demanda por takeaway:** Porque es competencia relacionada o sustitutiva (comida rápida de paso), pero menos directa.
- • **0,2 para los locales vacíos:** Porque tener locales vacíos cerca es una condición necesaria para entrar, no una medida de demanda de clientes; además, el filtro de al menos 15 locales vacíos ya garantiza que hay locales suficientes entre los que elegir.

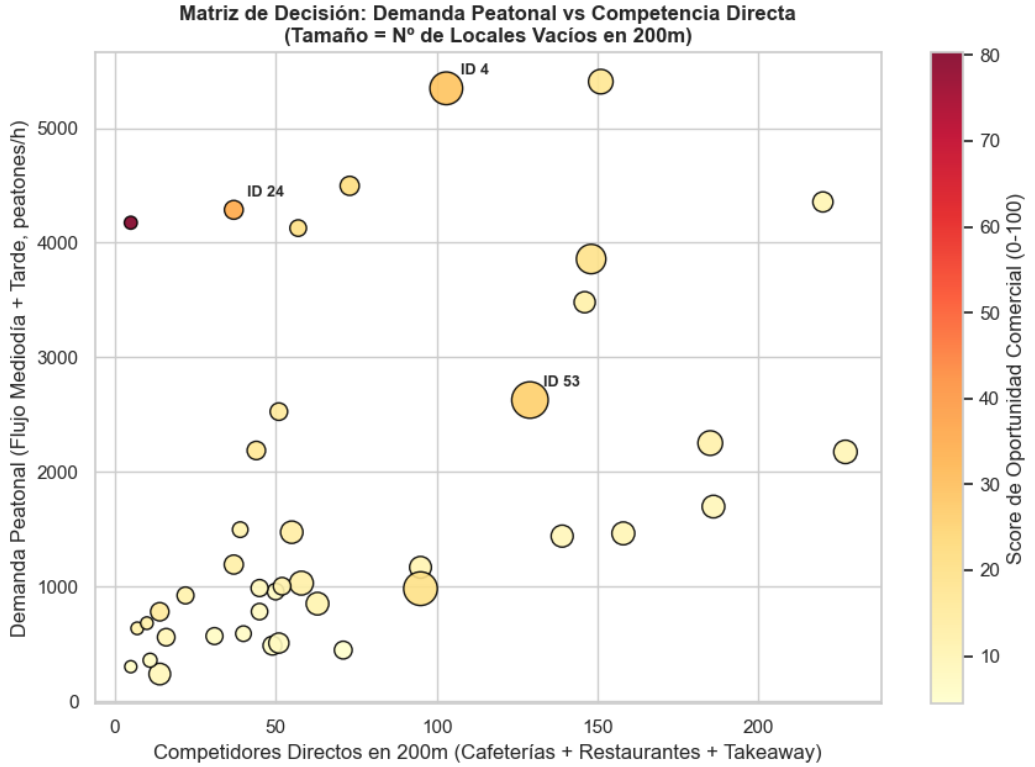


Figura 6. Matriz de decisión comercial: Demanda peatonal frente a Competidores directos (tamaño = locales vacíos en 200 m).

Al ordenar los sensores por este Score (Figura 6) y cruzar las coordenadas de los 3 sensores ganadores (IDs 24, 4 y 53) con el fichero establecimientos_2019.csv en un radio corto de 120 metros, el modelo devuelve las direcciones postales exactas de los locales vacíos más cercanos y el encaje del café saludable en cada calle según su perfil horario:

Ranking y Sensor	Perfil y Cifras Clave	Direcciones Exactas Recomendadas (Vacant Space)	Encaje del café saludable
#1. Sensor ID 24 Spencer St-Collins St (North) Score: 35,2	Arterias Prime (K-Means) 1.989 peat./h al mediodía Solo 29 cafés y 8 takeaways (126,1 peat./café) | 39 vacíos	• Shop 1, 608-610 Collins St (a 30,5 m) • Shop 4, 608-610 Collins St (a 30,5 m) • Shop 5, 608-610 Collins St (a 30,5 m)	Mayor demanda por competidor (126,1 peat./café): casi 2.000 peat./h al mediodía con solo 29 cafés a 200 m. Es la zona donde un café saludable tiene menos competencia directa y flujo alto, a unos 350 m a pie de la estación Southern Cross.
#2. Sensor ID 4 Town Hall (West) Score: 28,9	Arterias Prime y Anomalía (-1) 2.882 peat./h al mediodía 66 cafés y 37 takeaways (75,3 peat./café) | 175 vacíos	• Level 4, 123 Swanston St (a 18,7 m) • 125-133 Swanston St (a 29,9 m) • 133 Swanston St (a 29,9 m)	Máximo flujo de las tres zonas (2.882 peat./h al mediodía y 2.465 por la tarde). Hay más competencia (66 cafés), pero la demanda por café sigue siendo alta (75,3) y los 175 locales vacíos dan mucho margen para elegir ubicación. Encaja como apuesta de volumen y comparte entorno con el sensor 53.
#3. Sensor ID 53 Collins Street (North) Score: 25,5	Ocio/Gastronomía y Anomalía (-1) 1.683 peat./h al mediodía 86 cafés | 119 oficinas Máximo de 224 locales vacíos	• Basement, 252 Collins St (a 19,4 m) • Ground, 252 Collins St (a 19,4 m) • Level 1, 252 Collins St (a 19,4 m)	Entorno de oficinas (119 en 200 m) y arquetipo Ocio y Gastronomía, con actividad también en fin de semana. Hay 86 cafés cercanos y menos flujo por la tarde (944 peat./h), pero tiene el mayor número de locales vacíos de los 41 sensores (224, parte de ellos compartidos con el sensor 4). Encaja como apuesta de público laboral con oferta inmobiliaria amplia.

Nota: los 175 y 224 locales vacíos de los sensores 4 y 53 no son sumables, ya que ambos sensores comparten parte de ellos (véase el apartado 6.6).

Para conectar el clustering con la recomendación, calculé también el sensor con mayor Score de Oportunidad dentro de cada arquetipo de K-Means++ (siempre entre los que cumplen el filtro de al menos 15 locales vacíos):

Arquetipo K-Means++ (Sensores)	Mejor sensor del grupo	Flujo Mediodía (peat./h)	Cafés / Locales Vacíos (200 m)	Score

Arterias Prime Alto Flujo (7)	ID 24: Spencer St-Collins St (North)	1.989,2	29 / 39	35,2
Ocio, Finde y Gastronomía (9)	ID 53: Collins Street (North)	1.683,1	86 / 224	25,5
Tránsito Laborable / Oficinas (25)	ID 9: Southern Cross Station	869,2	21 / 36	16,6

Town Hall West (ID 4, Score 28,9) es el segundo mejor sensor de las Arterias Prime, por lo que no aparece como el mejor de su grupo, pero sí forma parte del Top 3 global. Lo más llamativo es que el mejor sensor de las calles de tránsito laborable puntúa menos de la mitad que el de las arterias principales (16,6 frente a 35,2), lo que indica un potencial claramente menor para este negocio. Además, el sensor 9 (Southern Cross Station) está a 323 m del sensor 24, por lo que es una zona contigua y no una recomendación independiente.

Después, para comprobar que estas tres zonas no salieron ganadoras por haber puesto yo a mano los pesos 0,5 / 0,3 / 0,2, programé en la última celda un análisis de sensibilidad con 5.000 combinaciones aleatorias de pesos que suman 1 (usando una distribución de Dirichlet). El resultado confirma la solidez de la decisión: Town Hall West (ID 4) sale en el Top 3 en el 87,3% de las 5.000 simulaciones, Collins Street North (ID 53) en el 70,6% y Spencer St-Collins St North (ID 24) en el 60,2%, muy por delante del cuarto sensor (Queen St West con un 39,7%). Es decir, elegí los pesos por criterio de negocio y luego comprobé que la conclusión se mantiene igual aunque cambies la ponderación. Hay que matizar que los sensores 4 y 53 comparten entorno (véase el apartado 6.6), por lo que sus porcentajes no son pruebas independientes.

6.6. Validación espacial del Top 3

Como verificación final, representé en un mapa los tres sensores ganadores con su radio de influencia de 200 m (Figura 7). El mapa muestra que los sensores 4 (Town Hall West) y 53 (Collins Street North) están separados por solo 99 m, por lo que sus radios se solapan en gran medida y comparten parte de su entorno comercial. Para cuantificarlo, calculé los establecimientos únicos que quedan dentro de la unión de ambos radios: en total hay 247 locales vacíos, y no los 399 que resultan de sumar los de cada sensor por separado (175 y 224), y 97 cafés y restaurantes, frente a los 152 de la suma simple. Es decir, alrededor del 38% de los locales vacíos de la suma simple y el 36% de los cafés quedan contados dos veces. El sensor 24 (Spencer St-Collins St) se encuentra a 1.033 m del 53 y a 1.113 m del 4, por lo que es una zona independiente.

En consecuencia, el Top 3 de sensores equivale a dos zonas comerciales distintas: el entorno de Spencer St-Collins St y el eje Collins St-Swanston St. Este hallazgo no altera el clustering, que trabaja a nivel de sensor, ni el score de cada sensor, pero obliga a no sumar las cifras de sensores vecinos y a interpretar la recomendación como dos zonas candidatas, no tres. También implica que los porcentajes del análisis de sensibilidad de los sensores 4 y 53 no son pruebas independientes, ya que ambos comparten entorno: lo que muestran es la solidez de la zona Collins-Swanston en su conjunto.

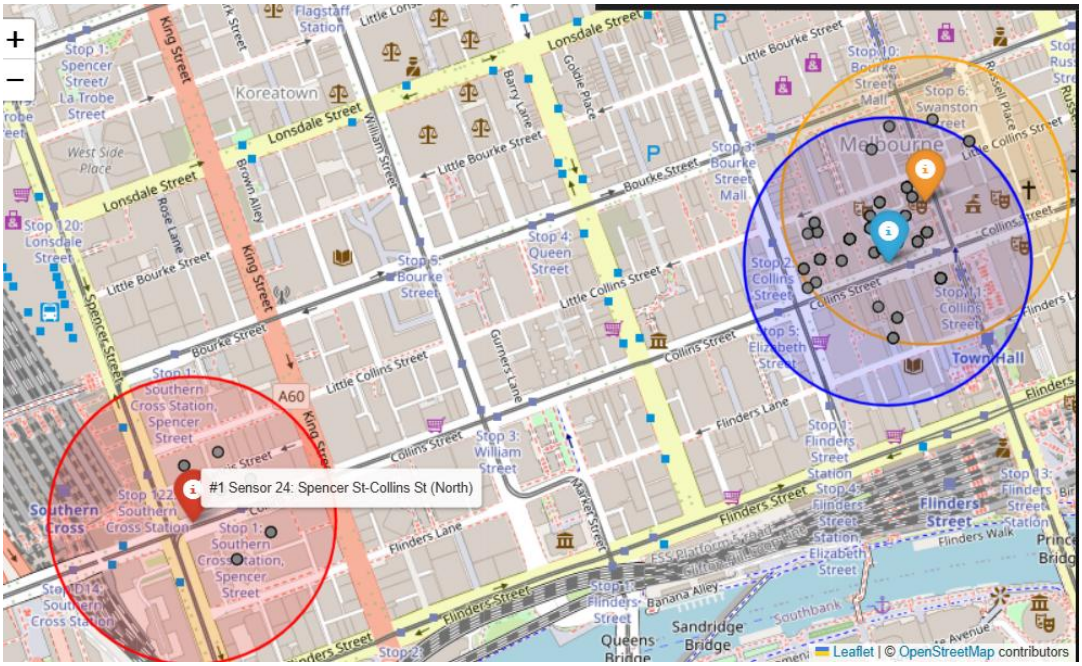


Figura 7. Top 3 de sensores con su radio de influencia de 200 m y los locales vacíos a menos de 120 m. Los sensores 4 y 53 comparten gran parte de su zona de influencia.

7. Conclusiones

- **1. El volumen anual de peatones por sí solo engaña:** Cruzar los conteos horarios con el censo comercial demostró que calles famosas como Bourke Street Mall tienen muchísimo tráfico pero están saturadas de competidores, mientras que otros nodos como el cruce de Spencer St y Collins St (Sensor 24) ofrecen casi 2.000 peatones por hora al mediodía con tres veces menos competencia directa.
- **2. Los datos de Melbourne tienen una estructura clara en 3 perfiles:** El estadístico de Hopkins (H = 0,7490) confirmó que el agrupamiento no es azaroso, el PCA permitió resumir el 71,0% de la varianza en solo 2 dimensiones, y tanto el método del codo en K-Means++ como el clustering jerárquico coincidieron en dividir la ciudad en 3 grupos bien diferenciados: calles de tránsito laborable (25), zonas de ocio y gastronomía (9) y arterias prime de alto flujo (7).
- **3. K-Means++ y DBSCAN funcionan mejor juntos que por separado:** Al evaluar los modelos con las métricas vimos que K-Means++ es el más estable frente al ruido aleatorio (ARI = 0,897), mientras que DBSCAN obtiene la mejor cohesión interna (Silueta = 0,423) al aislar como ruido (-1) las 4 esquinas más extremas de la ciudad, de las cuales dos (Town Hall West y Collins St North), situadas a solo 99 m una de otra, forman en la práctica un mismo foco de gran oportunidad inmobiliaria.
- **4. Recomendación aplicable y verificada:** El modelo permite pasar de 456.829 registros en bruto a recomendar direcciones concretas a menos de 31 metros de los sensores ganadores (como 608-610 Collins St, 123-133 Swanston St y 252 Collins St), demostrando mediante 5.000 simulaciones aleatorias que el Top 3 recomendado es robusto y no depende de una elección subjetiva de los pesos. Tras la validación espacial, ese Top 3 se interpreta como dos zonas comerciales (Spencer St-

Collins St y el eje Collins St-Swanston St) y no como tres independientes, y el análisis por arquetipos (sensores 24, 53 y 9) conecta el clustering con la recomendación.

- **5. Limitaciones del modelo:** El concepto “café saludable” es un criterio de negocio y no un resultado del modelo: la clasificación ANZSIC del censo no distingue entre cafeterías convencionales y saludables, por lo que la competencia se mide con todas las cafeterías y locales de comida para llevar del entorno. Además, los locales vacíos (Vacant Space) no implican que estén en alquiler y no se dispone de datos de alquileres ni de ventas, y los sensores cercanos (como el 4 y el 53) comparten entorno, por lo que sus cifras no son independientes. Por todo ello, los resultados deben entenderse como zonas candidatas a validar sobre el terreno.